UNIVERSIDAD PRIVADA DEL VALLE • BOLIVIA •

FACULTAD DE POSTGRADO

FACULTAD DE
POSTGRADO

Diplomado en Big Data, Analytics y Business Intelligence

Transformación Digital y Fundamentos de Big Data

36 años UNIVALLE

M. Sc. Marcelo Pinto Macedo

UNIVERSIDAD PRIVADA DEL VALLE • BOLIVIA •

FACULTAD DE
POSTGRADO

Python aplicado al Análisis de Datos

Qué es un Dataset

- Un **dataset (conjunto de datos)** es simplemente una colección organizada de información que se utiliza para análisis.
- Puede estar almacenado en diferentes formatos:
  - CSV
  - Excel
  - base de datos
  - JSON
  - API
  - archivos de logs
  - data lake

Qué es un DataFrame

- Un **DataFrame** es una **estructura de datos de la librería Pandas** que permite trabajar con datasets dentro de Python.
- Es decir:
  - Dataset = datos
    DataFrame = estructura que permite analizarlos en Python
- Cuando cargamos un dataset con Pandas, ocurre esto:
  - import pandas as pd
    df = pd.read_csv("titanic.csv")
- Aquí:
  - titanic.csv es el **dataset**
  - df es el **DataFrame**
- El DataFrame es como una **tabla inteligente** que permite:
  - filtrar datos
  - agrupar datos
  - calcular estadísticas
  - generar gráficos

Analogía

- **Dataset = libro de datos**
- **DataFrame = mesa de trabajo donde analizamos ese libro**
- Es decir:
- el dataset contiene la información
- el DataFrame permite manipularla

Dataset Titanic

Variable	Significado
Survived	sobrevivió (1) o no (0)
Pclass	clase del pasajero
Sex	sexo
Age	edad
Fare	precio del ticket
Embarked	puerto de embarque C = Cherbourg Q = Queenstown S = Southampton

Pipeline de Análisis de Datos