UNIVERSIDAD PRIVADA DEL VALLE • BOLIVIA •

FACULTAD DE POSTGRADO

FACULTAD DE
POSTGRADO

Diplomado en Big Data, Analytics y Business Intelligence

Transformación Digital y Fundamentos de Big Data

36 años UNIVALLE

M. Sc. Marcelo Pinto Macedo

UNIVERSIDAD PRIVADA DEL VALLE • BOLIVIA •

FACULTAD DE
POSTGRADO

Introducción al análisis de datos con Python

El problema organizacional del análisis de datos

- En el contexto actual, las organizaciones enfrentan tres desafíos principales:
- **Volumen de información**
- **Complejidad de los datos**
- **Velocidad de generación**

La necesidad de herramientas analíticas

- Para enfrentar estos desafíos, las organizaciones utilizan herramientas que permiten:
  - explorar datos
  - analizarlos
  - identificar patrones
  - generar conocimiento.
- Estas herramientas forman parte del **ecosistema de análisis de datos**.

Ecosistema de herramientas de análisis de datos

Tipo de herramienta	Ejemplos	Propósito
Herramientas de bases de datos	SQL, PostgreSQL	almacenar datos
Herramientas de análisis	Python, R	analizar datos
Herramientas de visualización	Power BI, Tableau	comunicar resultados
Plataformas de Big Data	Hadoop, Spark	procesar grandes volúmenes

¿Por qué Python se utiliza en análisis de datos?

- Python se ha convertido en una de las herramientas más utilizadas en ciencia de datos por varias razones:
- **1. Facilidad de aprendizaje**
- **2. Amplio ecosistema de bibliotecas**
- **3. Integración con Big Data**
- **4. Uso generalizado en la industria**

El rol de Python en el proceso de análisis de datos

- Para comprender mejor su función, es útil presentar el **flujo de trabajo del análisis de datos**.
- Proceso típico:
  - Recolección de datos
  - Limpieza de datos
  - **Exploración y análisis**
  - **Visualización**
  - Generación de insights

UNIVERSIDAD PRIVADA DEL VALLE • BOLIVIA •

FACULTAD DE
POSTGRADO

Entorno de Trabajo para Análisis de Datos

El concepto de Notebook de análisis

- Un notebook de análisis es un documento interactivo que permite combinar tres elementos:

1. texto explicativo
2. código ejecutable
3. resultados del análisis

Estructura de un notebook

- Un notebook está compuesto por celdas.
- Existen principalmente dos tipos.
- **Celdas de texto**
- Se utilizan para:
  - explicar el análisis
  - documentar decisiones
  - describir resultados.
- Estas celdas pueden incluir:
  - texto
  - títulos
  - ecuaciones
  - listas.

Estructura de un notebook

- **Celdas de código**
- Se utilizan para ejecutar instrucciones en Python.
- Ejemplo conceptual:
  - leer dataset
  - calcular promedio
  - generar gráfico
- Cuando se ejecuta la celda, el notebook muestra:
  - el resultado
  - tablas
  - gráficos.

Ventajas del uso de notebooks

- Los notebooks se utilizan ampliamente en ciencia de datos porque permiten:
- **Transparencia del análisis**
- **Reproducibilidad**
- **Integración de análisis y explicación**

Herramientas utilizadas para notebooks

Herramienta	Características
Jupyter Notebook	entorno clásico de análisis
Google Colab	versión en la nube basada en Jupyter
Databricks	entorno para análisis en Big Data

Demostración

- Dónde escribir código
- Dónde aparecen resultados
- Cómo ejecutar una celda.

UNIVERSIDAD PRIVADA DEL VALLE • BOLIVIA •

FACULTAD DE
POSTGRADO

Fundamentos de Python Orientado a Datos

Concepto de variable

- En Python, una **variable** es un nombre que se utiliza para almacenar información.
- Ejemplo simple:
- ventas = 100
- Interpretación:
  - **ventas** es el nombre de la variable
  - **100** es el valor almacenado.

Tipos básicos de datos

Tipo	Ejemplo	Uso
Enteros	10	conteos
Decimales	10.5	mediciones
Texto	"Cliente A"	nombres
Booleanos	True / False	condiciones

Ejemplo

- precio = 50.75
- cliente = "Empresa A"
- activo = True

Listas de datos

- En análisis de datos es común trabajar con **conjuntos de valores**.
- Python permite almacenarlos en **listas**.
- Ejemplo:
- ventas = [100, 120, 150, 200]
- Esto representa varias observaciones de ventas.

Interpretación

- Cada elemento de la lista corresponde a un registro.
- Por ejemplo:

Observación	Ventas
1	100
2	120
3	150
4	200

Operaciones básicas con listas

- Podemos calcular estadísticas simples.
- Ejemplo:
- sum(ventas)
- Resultado: suma de todos los valores.
- Promedio:
- sum(ventas) / len(ventas)

Diccionarios (estructura clave para datos)

- Los **diccionarios** permiten almacenar información estructurada.
- Ejemplo:
- cliente = {
- "nombre": "Empresa A",
- "ventas": 200,
- "region": "La Paz"
- }

Introducción al concepto de tabla de datos

- En análisis de datos, normalmente no trabajamos con listas aisladas.
- Trabajamos con **tablas de información**.
- Ejemplo conceptual:

Cliente	Región	Ventas
Empresa A	La Paz	200
Empresa B	Santa Cruz	350
Empresa C	Cochabamba	150

Este tipo de estructura será gestionado mediante **Pandas**.

UNIVERSIDAD PRIVADA DEL VALLE • BOLIVIA •

FACULTAD DE
POSTGRADO

Introducción al análisis de datos con Pandas

¿Qué es Pandas?

- Pandas es una biblioteca de Python diseñada para manipular, explorar y analizar datos estructurados, utilizando estructuras llamadas DataFrame, que funcionan de manera similar a una hoja de cálculo.
- Características importantes para el diplomado:
  - permite manejar grandes volúmenes de datos
  - permite limpiar información
  - permite resumir datos
  - permite preparar información para modelos analíticos
- DataFrame = tabla de datos.

Estructura de un DataFrame

- Un DataFrame está compuesto por tres elementos principales:
- Columnas
  Representan variables o atributos.
- Filas
  Representan observaciones o registros.
- Índice
  Identificador de cada fila.

Estructura de un DataFrame

- Ejemplo conceptual:
- Empresa | Región | Ventas
  Empresa A | La Paz | 200
  Empresa B | Santa Cruz | 350
  Empresa C | Cochabamba | 150

- “Cada fila representa una observación. Cada columna representa una variable que describe esa observación.”

Análisis sobre una tabla

- import pandas as pd

- datos = {
- "empresa": ["Empresa A", "Empresa B", "Empresa C", "Empresa D"],
- "region": ["La Paz", "Santa Cruz", "Cochabamba", "Tarija"],
- "ventas": [200, 350, 150, 400]
- }

- df = pd.DataFrame(datos)

- print(df)

Exploración básica de datos

- df.head()
  - Muestra las primeras filas de la tabla.
  - Esto es útil cuando el conjunto de datos es grande.
- df.info()
- Permite observar:
  - número de filas
  - número de columnas
  - tipo de datos

Estadísticas básicas

- df.describe()
- Calcula automáticamente:
  - promedio
  - mínimo
  - máximo
  - desviación estándar

Operaciones analíticas simples

- **Promedio de ventas**
- df["ventas"].mean()
- Interpretación:
  - Promedio de ventas del conjunto de empresas.
- **Empresa con mayor venta**
- df.loc[df["ventas"].idxmax()]
- Explicación:
  - Encuentra la fila donde las ventas son mayores.

Operaciones analíticas simples

- Agrupación por región
- df.groupby("region")["ventas"].sum()
- Explicación:
  - Agrupa los datos y suma las ventas por región.
  - Este tipo de operación es muy común en análisis organizacional.

UNIVERSIDAD PRIVADA DEL VALLE • BOLIVIA •

FACULTAD DE
POSTGRADO

Carga de datos para análisis

Fuentes comunes de datos en análisis organizacional

Fuente	Ejemplo
Sistemas transaccionales	ERP, CRM
Archivos exportados	Excel, CSV
Plataformas digitales	logs de aplicaciones
APIs	servicios externos
Sensores	IoT
Data warehouses	repositorios analíticos

¿Qué es un archivo CSV?

- CSV significa **Comma Separated Values**.
- Es un archivo de texto donde los datos se organizan en forma de tabla.
- Ejemplo conceptual:
  - empresa,region,ventas
    Empresa A,La Paz,200
    Empresa B,Santa Cruz,350
    Empresa C,Cochabamba,150

Carga de datos en Python con Pandas

- **Importar biblioteca**
- import pandas as pd
- Explicación:
- Pandas es la biblioteca que utilizamos para trabajar con tablas de datos.
- **Cargar archivo CSV**
- df = pd.read_csv("ventas_empresas.csv")
- Explicación paso a paso:
  - pd es el alias de pandas
  - read_csv() es la función que carga el archivo
  - "ventas_empresas.csv" es el dataset
- Resultado:
- El archivo se convierte en un **DataFrame**.

Visualización inicial del dataset

- Antes de analizar, debemos **mirar los datos**.
- **Mostrar primeras filas**
- df.head()
- Explicación:
- Muestra las primeras filas del dataset.
- Esto permite verificar:
  - estructura
  - variables
  - tipo de datos

Visualización inicial del dataset

- **Mostrar últimas filas**
- df.tail()
- Sirve para verificar la parte final del dataset.

Comprensión estructural del dataset

- **Información general**
- df.info
- Esto permite observar:
  - número de filas
  - número de columnas
  - tipo de datos
  - valores nulos

Comprensión estructural del dataset

- **Dimensión del dataset**
- df.shape
- Resultado:
- (número de filas, número de columnas)
- Ejemplo:
  - (1000, 5)
- Esto significa:
  - 1000 registros
    5 variables

Identificación de variables

- Cada columna representa una **variable analítica**.

empresa	region	ventas	fecha	canal

- Interpretación:
- empresa = variable categórica
  ventas = variable numérica
  fecha = variable temporal

UNIVERSIDAD PRIVADA DEL VALLE • BOLIVIA •

FACULTAD DE
POSTGRADO

Exploración inicial de datos

Exploración de datos

- En ciencia de datos este proceso se conoce como:
- **EDA – Exploratory Data Analysis**
- La exploración de datos consiste en examinar la estructura, características y patrones iniciales de un dataset para comprender su comportamiento.
- Objetivos del EDA:
  - comprender las variables
  - detectar problemas en los datos
  - identificar patrones iniciales
  - preparar el análisis posterior

Identificación de variables y tipos de datos

Tipo	Ejemplo
Numérica	ventas, ingresos
Categórica	región, producto
Temporal	fecha
Identificador	id_cliente

Ejemplo de dataset

empresa	region	ventas	empleados
Empresa A	La Paz	200	15
Empresa B	Santa Cruz	350	20
Empresa C	Cochabamba	150	12

Código para ver tipos de datos

- df.dtypes
- Explicación:
- Esto muestra el **tipo de dato de cada variable**.
- Ejemplo de salida:
  - empresa = object
    region = object
    ventas = int64
    empleados = int64
- Interpretación:
  - object = texto
  - int = número entero
  - float = número decimal

Estadísticas descriptivas iniciales

- Una vez identificadas las variables, el siguiente paso es obtener **estadísticas básicas del dataset**.
- Estas estadísticas permiten responder preguntas como:
  - ¿Cuál es el promedio de ventas?
  - ¿Cuál es el valor máximo?
  - ¿Existe mucha variabilidad?

Estadísticas automáticas con Pandas

- df.describe()

estadística	ventas
count	100
mean	230
std	50
min	120
max	400

Exploración básica de variables categóricas

- Las variables categóricas describen **grupos o categorías**.
- Ejemplo:
  - región
  - Sector
  - tipo de cliente
- Para analizarlas utilizamos:
- df["region"].value_counts()

Exploración de columnas específicas

- Podemos analizar una variable individual.
- Ejemplo:
- **Promedio de ventas**
- df["ventas"].mean()
- **Valor máximo**
- df["ventas"].max()
- **Valor mínimo**
- df["ventas"].min()

Agrupación de datos

- Una operación analítica muy común es **agrupar datos por categorías**.
- Ejemplo:
- Ventas por región.
- df.groupby("region")["ventas"].sum()

Interpretación analítica

- El análisis de datos no termina en el cálculo.
- Lo importante es **interpretar los resultados**.
- Ejemplo:
- Si observamos que:
- Santa Cruz tiene mayores ventas
- podríamos plantear preguntas como:
  - ¿existe mayor mercado en esa región?
  - ¿existen más clientes?
  - ¿existe mayor inversión comercial?
- Esto convierte datos en **conocimiento organizacional**.