

DATA DISCOVERY

y Análisis Exploratorio (EDA)

Diplomado en Big Data, Analytics y Business Intelligence

Unidad 2

Contenidos

- Concepto de Data Discovery
- Exploración de datos (EDA)
- Identificación de patrones, tendencias y outliers
- KPIs y métricas de negocio
- Análisis visual para toma de decisiones



Actividad Práctica

Exploración visual de un dataset
empresarial



Agenda

- | | | | |
|----|---|---------------------------------|--|
| 01 |  | Concepto de Data Discovery | <i>Qué es y por qué importa</i> |
| 02 |  | Exploración de Datos (EDA) | <i>Técnicas y herramientas fundamentales</i> |
| 03 |  | Patrones, Tendencias y Outliers | <i>Casos reales multi-sector</i> |
| 04 |  | KPIs y Métricas de Negocio | <i>Indicadores que impulsan decisiones</i> |
| 05 |  | Análisis Visual para Decisiones | <i>De datos a acción estratégica</i> |

¿Qué es Data Discovery?

El proceso de recopilar, explorar y analizar datos de múltiples fuentes para encontrar patrones, relaciones y oportunidades ocultas.

Recolección

Integración de fuentes diversas (bases de datos, APIs, archivos)

Exploración

Análisis visual e interactivo para entender la estructura

Descubrimiento

Identificación de insights y relaciones no evidentes

Impacto

80%

del tiempo de un analista se dedica a descubrir y preparar datos

5x

mayor velocidad de insights con herramientas de Data Discovery

60%

de las empresas Fortune 500 usan Data Discovery activamente

El Proceso de Data Discovery

De datos en crudo a insights accionables



Herramientas: Power BI | Tableau | Looker Studio | Python (Pandas, Matplotlib, Seaborn)

Caso Real: Netflix

Data Discovery en acción

Datos que Netflix explora

- Comportamiento de visualización (qué ven, cuándo pausan, cuándo abandonan)
- Patrones de búsqueda y contenido no consumido (demanda latente)
- Señales sociales (compartir, listas, valoraciones)
- Análisis de audio del contenido (tempo, energía, características acústicas)
- Contexto: hora del día, dispositivo, ubicación general

Motor de Recomendación

222M

suscriptores globales en 190+ países



Collaborative Filtering

Usuarios con gustos similares

NLP

Análisis de reseñas y blogs

Deep Learning

Análisis acústico del contenido

El 80% de lo que los usuarios ven en Netflix proviene de recomendaciones algorítmicas

Exploración de Datos (EDA)

Exploratory Data Analysis — John Tukey, 1977

"Un enfoque para analizar datos que maximiza el entendimiento a través de visualización, resumen y transformación, permitiendo descubrir lo inesperado."



Estadísticas Descriptivas

Media, mediana, moda
Varianza, desviación
Cuartiles, percentiles



Visualización de Distribución

Histogramas
Box plots
Densidad (KDE)



Análisis de Relaciones

Scatter plots
Matrices de correlación
Heatmaps



Limpieza y Transformación

Missing values
Normalización
Feature engineering

¿Por qué visualizar? Cuarteto de Anscombe

4 datasets, estadísticas idénticas, distribuciones completamente diferentes — Francis Anscombe, 1973

Todos comparten: Media $X = 9$ | Media $Y = 7.50$ | Varianza $X = 11$ | Correlación = 0.816 | Regresión: $Y = 3.00 + 0.500X$

Técnicas de Visualización en EDA

Histograma

Uso: Distribución de una variable

Cuándo: Entender la forma de los datos

Ej: *Distribución de edades de clientes*

Box Plot

Uso: Dispersión y outliers

Cuándo: Comparar grupos, detectar anomalías

Ej: *Salarios por departamento*

Scatter Plot

Uso: Relación entre 2 variables

Cuándo: Buscar correlaciones

Ej: *Precio vs. demanda de productos*

Heatmap

Uso: Correlación multivariable

Cuándo: Entender relaciones complejas

Ej: *Correlación entre métricas financieras*

Line Chart

Uso: Tendencias temporales

Cuándo: Analizar evolución y estacionalidad

Ej: *Ventas mensuales por categoría*

Bar Chart

Uso: Comparación categórica

Cuándo: Ranking y composición

Ej: *Top 10 productos por ingresos*



Identificación de Patrones y Tendencias

Tendencias

Dirección general de los datos en el tiempo. Ascendente, descendente o estacionaria.

Crecimiento trimestral de ventas en retail

Estacionalidad

Patrones que se repiten en intervalos regulares (diario, semanal, anual).

Picos de venta en Black Friday y Navidad (Walmart)

Ciclos

Fluctuaciones a largo plazo sin periodicidad fija, asociadas a factores económicos.

Ciclos de demanda inmobiliaria

Correlaciones

Relaciones entre variables que pueden revelar causalidad o asociación.

Temperatura vs. consumo energético

Walmart detectó que las ventas de Pop-Tarts aumentaban antes de huracanes mediante EDA