

Telemetría Avanzada & Auditoría de Red: Dashboard Integrado NOC/SOC para Detección de Amenazas en Entornos Controlados

Ing. Ilian Joseph Felipez Vaca
Universidad Privada del Valle – Facultad de Postgrado
Diplomado en Big Data, Analytics y Business Intelligence
Módulo: Visualización de Datos y Data Discovery
La Paz – Bolivia, 2026
Email: ilian.felipezvaca@postgrado.univalle.edu

Abstract—El presente proyecto aborda el diseño e implementación de un dashboard interactivo para el monitoreo de tráfico de red, orientado a Centros de Operación de Red (NOC) y Centros de Operación de Seguridad (SOC). Desarrollado en Microsoft Power BI a partir del dataset *Network Threat Detection* (Kaggle), el sistema integra métricas clave de rendimiento, visualizaciones de patrones de comunicación y detección de anomalías. Se presentan los fundamentos técnicos, la arquitectura de datos, las medidas DAX implementadas y los hallazgos preliminares. La solución constituye una herramienta de apoyo para la toma de decisiones en entornos de simulación de ciberataques y entrenamiento de personal SOC.

I. INTRODUCCIÓN

La creciente sofisticación de las amenazas cibernéticas exige herramientas de monitoreo que integren capacidades operativas y de seguridad. Los centros NOC y SOC requieren plataformas unificadas que permitan visualizar, con datos históricos o en tiempo real, el comportamiento del tráfico de red y detectar desviaciones significativas.

El presente proyecto aborda esta necesidad mediante el diseño de un dashboard en Power BI, utilizando el dataset *Network Threat Detection* [1], el cual contiene registros de flujos de red provenientes de un entorno controlado con ataques simulados. Los objetivos específicos son:

- 1) Caracterizar el volumen y naturaleza del tráfico en un escenario de alta amenaza.
- 2) Identificar dispositivos, servicios y puertos con mayor actividad.
- 3) Detectar patrones anómalos compatibles con escaneos, flooding o túneles DNS.
- 4) Proveer una interfaz dual (NOC/SOC) que separe funciones operativas de seguridad.

II. DESCRIPCIÓN DE LA FUENTE DE DATOS

A. Origen y Contexto

Los datos utilizados corresponden al dataset *Network Threat Detection*, publicado por Rebson Ramalho en la plataforma Kaggle [1]. Fue generado en un entorno de infraestructura virtual controlado y replicable, diseñado para simular escenarios

reales de seguridad. La infraestructura incluye tres máquinas virtuales con roles definidos:

- **Kali Linux (atacante):** versión 2025.2
- **Metasploitable (objetivo vulnerable):** kernel antiguo
- **Ubuntu 24.04.2 LTS (sensor/IDS):** con Suricata y ELK stack

El sensor Suricata operó como IDS pasivo registrando eventos en JSON, mientras que tcpdump/tshark realizaron la captura a nivel de paquete en formato CSV. Scripts en Python se encargaron de la conversión, integración temporal y estandarización de los artefactos en los conjuntos de datos finales.

B. Estructura y Volumen

El proyecto generó dos datasets con características distintas:

- **Dataset_completo:** 368,017 registros (336,735 maliciosos, 31,282 benignos). Conjunto voluminoso pero altamente desbalanceado, con predominancia de más del 90% de registros maliciosos.
- **Dataset_resumido:** 55,826 registros (29,546 ataques, 26,280 benignos). Volumen menor pero distribución más equilibrada entre clases.

Para el presente proyecto se utilizó el *Dataset_completo*, ya que su alto porcentaje de tráfico malicioso permite simular escenarios de alta amenaza y entrenar al personal SOC en condiciones extremas.

La Tabla I resume los campos principales utilizados en el análisis.

C. Ataques Simulados Incluidos

Según la documentación del dataset, se ejecutaron los siguientes vectores de ataque, representando las fases de un ciberataque (reconocimiento, explotación, post-explotación e impacto):

- DoS/DDoS (SYN Flood y ICMP Flood, incluyendo escenarios DDoS distribuidos)
- SSH Brute-Force
- Reverse Shells / canales de comando y control (C2)

TABLE I: Campos principales del dataset de tráfico de red

Campo	Tipo	Descripción
srcip	Texto	Dirección IP origen (atacante o víctima)
dstip	Texto	Dirección IP destino
sport / dsport	Numérico	Puerto origen / destino
proto	Texto	Protocolo (TCP, ICMP, IPv6-ICMP)
state	Texto	Estado de la conexión (new, closed, etc.)
dur	Numérico	Duración del flujo (segundos)
sbytes / dbytes	Numérico	Bytes enviados desde origen / destino
Stime / Ltime	Texto	Marca de tiempo de inicio y fin
label	Numérico	1 = ataque, 0 = benigno

- Local Privilege Escalation
- Simulación de Ransomware (escritura masiva de archivos)
- Exploit / PoC de vulnerabilidades conocidas
- SQL Injection contra aplicaciones web vulnerables
- Defacement (alteración maliciosa de contenido web)

Las herramientas empleadas para la generación de ataques incluyen: hping3, hydra, nmap, nessus, sqlmap, Metasploit y utilidades nativas de Kali Linux.

III. DISEÑO DEL DASHBOARD

A. Arquitectura Funcional y Navegación

El dashboard se organiza en dos pestañas principales, accesibles desde una pantalla de portada unificada. La Figura 1 presenta la interfaz de acceso, que actúa como menú centralizado entre los entornos NOC y SOC.



Fig. 1: Pantalla de acceso principal: “Telemetría Avanzada y Auditoría de Red”

B. Paleta de Colores

Se implementó una paleta de temática ciberseguridad con modo oscuro (*dark mode*) para reducir la fatiga visual del analista. La Figura 2 muestra la selección cromática utilizada en todos los elementos del dashboard.

La Tabla II especifica los códigos hexadecimales y su uso funcional.

C. Pestaña 1: Vista General de Tráfico (NOC)

La Figura 3 detalla el panel orientado a la supervisión operativa del volumen de red. En la sección superior se exponen cuatro métricas críticas:



Fig. 2: Paleta de colores institucional: fondo oscuro con acentos cian/verde neón

TABLE II: Paleta de colores implementada

Elemento	Código Hex	Uso
Fondo principal	#212121	Canvas general
Tarjetas y paneles	#323232	Contenedores de KPIs y gráficos
Color primario / acento	#0D7377	Bordes, encabezados, ejes
Neón / alerta	#14FFEC	KPIs destacados, elementos críticos

- **Total de Conexiones Registradas:** 368,017
- **Throughput:** 866.45 MB/s
- **Flows por hora promedio:** 706
- **Tasa de Anomalías (global):** 91.5% (refleja la composición del dataset)




Fig. 3: Pestaña NOC: Vista General de Tráfico con métricas operativas

El cuerpo del panel se organiza en cuatro cuadrantes analíticos:

- 1) **Top 5 IP de Origen** (barras horizontales): Identifica los dispositivos con mayor generación de tráfico.
- 2) **Distribución por Protocolo** (donut): TCP 59.90%, ICMP 36.10%, Otros 2.31%.
- 3) **Puertos Destino más Solicitados** (columnas): El puerto 53 (DNS) concentra 98K conexiones.
- 4) **Estado de Conexiones** (barras): 335K conexiones “Desconocidas”, 18K “Nuevas”, 14K “Cerradas”.

D. Pestaña 2: Análisis de Anomalías y Seguridad (SOC)

La Figura 4 ilustra el entorno optimizado para el triaje e investigación de incidentes. Este módulo hereda el contexto volumétrico (368K conexiones) pero redirige el enfoque hacia patrones de ataque y vectores de correlación.




Fig. 4: Pestaña SOC: Análisis de Anomalías y detección de amenazas

E. KPIs y Medidas DAX

Se implementaron las siguientes medidas en Power BI:

```
-- Total de flujos
TotalFlows = COUNTROWS('NetworkTraffic')

-- Throughput Dinamico en MB/s
Throughput =
VAR MinTimeRaw = MIN('NetworkTraffic'[Stime])
VAR MaxTimeRaw = MAX('NetworkTraffic'[Ltime])
VAR MinTimeDate =
    IF(
        ISBLANK(MinTimeRaw) || MinTimeRaw = "0" ||
        MinTimeRaw = "",
        BLANK(),
        IF(LEFT(MinTimeRaw, 3) = "202", CONVERT(LEFT(
            MinTimeRaw, 19), DATETIME),
            DATE(1970, 1, 1) + (VALUE(MinTimeRaw) / 86400))
    )
VAR MaxTimeDate =
    IF(
        ISBLANK(MaxTimeRaw) || MaxTimeRaw = "0" ||
        MaxTimeRaw = "",
        BLANK(),
        IF(LEFT(MaxTimeRaw, 3) = "202", CONVERT(LEFT(
            MaxTimeRaw, 19), DATETIME),
            DATE(1970, 1, 1) + (VALUE(MaxTimeRaw) / 86400))
    )
VAR DurationSeconds =
    IF(
        ISBLANK(MinTimeDate) || ISBLANK(MaxTimeDate) ||
        MinTimeDate = MaxTimeDate,
        1,
        VAR Dif = DATEDIFF(MinTimeDate, MaxTimeDate, SECOND)
        RETURN IF(Dif <= 0, 1, Dif)
    )
VAR TotalBytes = SUM('NetworkTraffic'[sbytes]) + SUM('
    NetworkTraffic'[dbytes])
RETURN DIVIDE(TotalBytes, DurationSeconds * 1024 * 1024, 0)

-- Flows por hora (dinamico)
FlowsPorHora =
VAR MinTimeRaw = MIN('NetworkTraffic'[Stime])
VAR MaxTimeRaw = MAX('NetworkTraffic'[Ltime])
VAR MinTimeDate =
    IF(LEFT(MinTimeRaw, 3) = "202", CONVERT(LEFT(MinTimeRaw
        , 19), DATETIME),
        DATE(1970, 1, 1) + (VALUE(MinTimeRaw) / 86400))
VAR MaxTimeDate =
    IF(LEFT(MaxTimeRaw, 3) = "202", CONVERT(LEFT(MaxTimeRaw
        , 19), DATETIME),
```

```
DATE(1970, 1, 1) + (VALUE(MaxTimeRaw) / 86400))
VAR TotalHoras = DATEDIFF(MinTimeDate, MaxTimeDate, HOUR) +
    1
RETURN DIVIDE([TotalFlows], TotalHoras, 0)

-- Tasa de anomalías
TasaAnomalías =
VAR Anomalías = CALCULATE(COUNTROWS('NetworkTraffic'), '
    NetworkTraffic'[label] = 1)
RETURN DIVIDE(Anomalías, [TotalFlows], 0)
```

IV. RESULTADOS Y HALLAZGOS

A. Contextualización de la Tasa de Anomalías

El dashboard arroja una tasa de anomalías del **91.5%** cuando se analiza el dataset completo sin filtros. Este valor, lejos de ser un error, **valida la fidelidad del tablero respecto a la fuente de datos**, ya que la documentación oficial de Kaggle para el *Dataset_completo* especifica textualmente:

“Dataset_completo: Composed of approximately 368,017 records, with 336,735 related to malicious traffic and 31,282 to benign traffic. It is a large-volume set but **highly imbalanced, with a predominance of over 90% malicious records.**” [1]

Por lo tanto, el dashboard refleja correctamente la naturaleza del dataset utilizado, demostrando que el sistema de visualización captura fielmente los datos subyacentes sin distorsión.

B. Hallazgos Cuantitativos Principales

La Tabla III resume los hallazgos más relevantes del análisis.

TABLE III: Hallazgos cuantitativos en el dataset de tráfico de red

Métrica	Valor	Interpretación
Tasa de Anomalías	91.5%	Diseño intencional del dataset (> 90% ataques).
IP origen dominante	192.168.56.102	Máquina atacante Kali Linux (documentado).
Puerto más solicitado	53 (DNS) – 98K flujos	Posible túnel DNS o exfiltración de datos.
Conexiones “Desconocidas”	335K (91%)	Flooding SYN/ICMP sin handshake.
Protocolo predominante	TCP 59.9% / ICMP 36.1%	ICMP elevado sugiere ping flood o sondeo.

C. Insights Estratégicos

A partir del análisis de los datos, se identificaron los siguientes insights de valor para la operación del SOC:

- **Concentración de ataque:** La IP 192.168.56.102 genera 487 conexiones (72% del tráfico hacia el objetivo), compatible con fuerza bruta o reconocimiento agresivo.
- **Túnel DNS potencial:** El puerto 53 concentra 98K conexiones, superando ampliamente al HTTP (21K). En redes sanas, DNS no suele ser el puerto más alto en volumen de conexiones.
- **Estado de conexiones atípico:** 91% de conexiones “Desconocidas” refleja ataques de flooding que no completan

el *three-way handshake* TCP, característico de SYN Flood attacks.

V. CONCLUSIONES

El dashboard desarrollado cumple con todos los requisitos técnicos establecidos en la consigna del módulo: dos pestañas funcionales (NOC y SOC), más de ocho visualizaciones distintas, KPIs con contexto y una paleta de colores coherente. La arquitectura dual permite separar claramente las funciones operativas de las de seguridad.

El hallazgo más significativo es la validación de que el tablero refleja fielmente la naturaleza del dataset utilizado (91.5% de tráfico malicioso), lo que demuestra una correcta interpretación de la fuente de datos y no un error de diseño. En un despliegue real con tráfico corporativo normal, se esperaría una tasa de anomalías inferior al 5%.

VI. RECOMENDACIONES FUTURAS

- 1) **Despliegue en entorno real:** Conectar el dashboard a logs de firewall o sensores IDS en una red corporativa para obtener métricas representativas.
- 2) **Automatización:** Programar actualización periódica de datos y alertas por correo cuando la tasa de anomalías supere umbrales definidos.
- 3) **Entrenamiento SOC:** Utilizar el dashboard como herramienta de capacitación para analistas junior, aprovechando el dataset etiquetado (ataque vs. benigno).
- 4) **Mejora de datos:** En versiones futuras, usar el *Dataset_resumido* (balanceado 50/50) para evaluar modelos de detección sin desbalance extremo.

VII. LIMITACIONES DEL ESTUDIO

La principal limitación radica en la naturaleza intencionalmente desbalanceada del dataset utilizado (91.5% de eventos maliciosos). Las métricas absolutas (especialmente la tasa de anomalías) no son extrapolables a entornos de red corporativos reales. El dashboard debe ser interpretado como una **herramienta de simulación y entrenamiento**, no como un diagnóstico de una red en producción.

Adicionalmente, las columnas temporales presentaban valores no estandarizados (formato UNIX timestamp y formato fecha combinados), lo que afectó el cálculo preciso del throughput horario. Este problema fue mitigado mediante la implementación de una medición DAX híbrida que detecta automáticamente el formato de fecha y aplica la conversión correspondiente.

REFERENCES

- [1] R. Ramalho, "Network Threat Detection Dataset," Kaggle, 2025. [Online]. Available: <https://www.kaggle.com/datasets/rebsonramalho/network-threat-detection-dataset>
- [2] S. Few, *Show Me the Numbers: Designing Tables and Graphs to Enlighten*, 2nd ed. Analytics Press, 2012.
- [3] C. N. Knaflitz, *Storytelling with Data: A Data Visualization Guide for Business Professionals*. Wiley, 2015.
- [4] S. Evergreen, *Effective Data Visualization: The Right Chart for the Right Data*, 2nd ed. SAGE Publications, 2019.
- [5] Microsoft Corporation, "Power BI Documentation," 2025. [Online]. Available: <https://learn.microsoft.com/en-us/power-bi/>

APPENDIX A MEDIDAS DAX COMPLETAS

```
-- Total de flujos
TotalFlows = COUNTROWS('NetworkTraffic')

-- Throughput Dinamico en MB/s (Correccion Hibrada de Fechas)
Throughput =
VAR MinTimeRaw = MIN('NetworkTraffic'[Stime])
VAR MaxTimeRaw = MAX('NetworkTraffic'[Ltime])
VAR MinTimeDate =
    IF(
        ISBLANK(MinTimeRaw) || MinTimeRaw = "0" ||
        MinTimeRaw = "",
        BLANK(),
        IF(LEFT(MinTimeRaw, 3) = "202", CONVERT(LEFT(
            MinTimeRaw, 19), DATETIME),
            DATE(1970, 1, 1) + (VALUE(MinTimeRaw) / 86400))
    )
VAR MaxTimeDate =
    IF(
        ISBLANK(MaxTimeRaw) || MaxTimeRaw = "0" ||
        MaxTimeRaw = "",
        BLANK(),
        IF(LEFT(MaxTimeRaw, 3) = "202", CONVERT(LEFT(
            MaxTimeRaw, 19), DATETIME),
            DATE(1970, 1, 1) + (VALUE(MaxTimeRaw) / 86400))
    )
VAR DurationSeconds =
    IF(
        ISBLANK(MinTimeDate) || ISBLANK(MaxTimeDate) ||
        MinTimeDate = MaxTimeDate,
        1,
        VAR Dif = DATEDIFF(MinTimeDate, MaxTimeDate, SECOND)
        RETURN IF(Dif <= 0, 1, Dif)
    )
VAR TotalBytes = SUM('NetworkTraffic'[sbytes]) + SUM('
    NetworkTraffic'[dbytes])
RETURN DIVIDE(TotalBytes, DurationSeconds * 1024 * 1024, 0)

-- Flows por hora (dinamico)
FlowsPorHora =
VAR MinTimeRaw = MIN('NetworkTraffic'[Stime])
VAR MaxTimeRaw = MAX('NetworkTraffic'[Ltime])
VAR MinTimeDate =
    IF(LEFT(MinTimeRaw, 3) = "202", CONVERT(LEFT(MinTimeRaw
        , 19), DATETIME),
        DATE(1970, 1, 1) + (VALUE(MinTimeRaw) / 86400))
VAR MaxTimeDate =
    IF(LEFT(MaxTimeRaw, 3) = "202", CONVERT(LEFT(MaxTimeRaw
        , 19), DATETIME),
        DATE(1970, 1, 1) + (VALUE(MaxTimeRaw) / 86400))
VAR TotalHoras = DATEDIFF(MinTimeDate, MaxTimeDate, HOUR) +
    1
RETURN DIVIDE([TotalFlows], TotalHoras, 0)

-- Tasa de anomalias (segun columna label)
TasaAnomalias =
VAR Anomalias = CALCULATE(COUNTROWS('NetworkTraffic'), '
    NetworkTraffic'[label] = 1)
RETURN DIVIDE(Anomalias, [TotalFlows], 0)

-- Total de bytes (para graficos)
TotalBytes = SUM('NetworkTraffic'[sbytes]) + SUM('
    NetworkTraffic'[dbytes])
```