

Aplicaciones de Big Data en Entornos Digitales

Diseño de Ecosistema Analítico

Caso 51. Retail – Optimización de ventas y comportamiento de clientes

Contexto

NovaMarket es una cadena internacional de comercio electrónico especializada en artículos para el hogar, electrónica y productos de consumo masivo. Durante los últimos tres años ha expandido sus operaciones a varios países de Latinoamérica y Europa, incrementando significativamente el volumen de transacciones y la cantidad de clientes registrados.

La empresa opera con un ecosistema tecnológico compuesto por **Shopify Plus** como plataforma de comercio electrónico, **Salesforce CRM** para la gestión de clientes, **SAP Business One** como sistema ERP y **Google Analytics 4 (GA4)** para el seguimiento del comportamiento de navegación. Además, el área comercial recibe diariamente archivos CSV provenientes de distribuidores externos y campañas de marketing digital administradas en **Google Ads** y **Meta Ads**.

Aunque la empresa dispone de una gran cantidad de información, los datos permanecen distribuidos en múltiples sistemas, dificultando la obtención de indicadores consolidados y la generación de análisis oportunos para la toma de decisiones.

Problemática

La gerencia comercial ha detectado que el incremento sostenido del tráfico web no se traduce en un crecimiento proporcional de las ventas. Existen diferencias importantes en el desempeño de las distintas categorías de productos, mercados y segmentos de clientes, pero actualmente no es posible identificar con precisión las causas.

La dirección desea implementar una arquitectura moderna de datos que permita integrar la información de todas las fuentes, construir un modelo analítico unificado y generar indicadores que respondan preguntas como:

- ¿Qué productos generan la mayor rentabilidad?
- ¿Qué países y canales concentran las ventas más importantes?
- ¿Qué clientes presentan mayor valor de vida (Customer Lifetime Value)?
- ¿Qué patrones de compra permiten identificar oportunidades de venta cruzada (Cross Selling)?
- ¿Cómo evolucionan las ventas y los ingresos a lo largo del tiempo?

El equipo deberá proponer una arquitectura ELT adecuada, seleccionar las herramientas más apropiadas para cada etapa y justificar técnicamente sus decisiones.

Fuentes de datos

La organización dispone de información proveniente de:

- **Shopify Plus** (pedidos, productos y comportamiento de compra)
- **Salesforce CRM** (clientes y segmentación)
- **SAP Business One** (facturación e inventario)
- **Google Analytics 4** (comportamiento de navegación)
- **Google Ads** y **Meta Ads** (campañas de marketing)
- Archivos **CSV** enviados por distribuidores y socios comerciales

Dataset de referencia (mockup): Online Retail II (UCI)

<https://www.kaggle.com/dvaser/online-retail-ii/data>

Aplicaciones de Big Data en Entornos Digitales

Diseño de Ecosistema Analítico

Caso 52. Telecomunicaciones – Reducción del abandono de clientes (Churn)

Contexto

AndesTel Comunicaciones es un operador regional de telefonía móvil e Internet con más de tres millones de clientes distribuidos en varios países de Sudamérica. La empresa ofrece servicios de telefonía móvil, fibra óptica, televisión por suscripción y paquetes convergentes para hogares y empresas.

La información operativa se encuentra distribuida entre diferentes plataformas: **Salesforce CRM** para la gestión comercial, **Oracle Billing and Revenue Management (BRM)** para la facturación, **Genesys Cloud** para la atención al cliente y un portal de autoservicio donde los usuarios realizan consultas, pagos y solicitudes.

Durante los últimos meses la empresa ha observado un incremento en la tasa de cancelación de contratos, afectando los ingresos recurrentes y elevando considerablemente los costos de adquisición de nuevos clientes.

Problemática

La dirección comercial necesita construir una plataforma analítica que permita comprender las causas del abandono de clientes y apoyar el diseño de campañas de fidelización.

Actualmente resulta complejo integrar información proveniente de facturación, atención al cliente, consumo de servicios y comportamiento digital, por lo que las decisiones se toman utilizando reportes parciales generados por diferentes áreas.

La organización desea responder preguntas como:

- ¿Qué características tienen los clientes con mayor probabilidad de cancelar el servicio?
- ¿Qué productos y planes presentan mejores niveles de retención?
- ¿Qué reclamos o incidencias anteceden con mayor frecuencia al abandono?
- ¿Qué segmentos deberían priorizarse en campañas de retención?
- ¿Cómo evoluciona mensualmente la tasa de churn?

El equipo deberá diseñar una arquitectura ELT moderna, seleccionar las herramientas más adecuadas para integrar, transformar y analizar la información, justificando cada decisión tecnológica.

Fuentes de datos

La empresa dispone de información proveniente de:

- **Salesforce CRM** (clientes y contratos)
- **Oracle BRM** (facturación y pagos)
- **Genesys Cloud** (atención al cliente)
- Portal web y aplicación móvil (interacciones digitales)
- Registros de consumo de servicios de telecomunicaciones
- Archivos históricos exportados en formato CSV

Dataset de referencia (mockup): Telecom Customer Churn

<https://www.kaggle.com/datasets/shivam131019/telecom-churn-dataset>

Aplicaciones de Big Data en Entornos Digitales

Diseño de Ecosistema Analítico

Caso 53. Salud – Optimización de citas médicas

Contexto

Red Salud Integral es una organización privada que administra una red de hospitales y clínicas especializadas en medicina general, pediatría, cardiología y diagnóstico por imágenes. Atiende aproximadamente un millón de consultas médicas al año y utiliza diferentes sistemas para gestionar la operación clínica y administrativa.

Las historias clínicas electrónicas se administran mediante **OpenEMR**, la programación de citas se realiza a través de un sistema desarrollado sobre **Microsoft SQL Server**, la facturación utiliza **Microsoft Dynamics 365 Business Central**, mientras que la gestión documental y algunos reportes continúan realizándose mediante hojas de cálculo de Microsoft Excel.

En los últimos meses la organización ha registrado un incremento significativo en las inasistencias de pacientes, generando tiempos muertos para el personal médico, baja utilización de consultorios y pérdidas económicas.

Problemática

La dirección médica desea implementar una plataforma analítica que permita integrar la información clínica y administrativa para comprender los factores asociados al ausentismo y mejorar la planificación de recursos.

Actualmente los reportes se elaboran manualmente, utilizando información proveniente de múltiples sistemas independientes, lo que dificulta el análisis oportuno y la identificación de patrones de comportamiento.

La organización necesita responder preguntas como:

- ¿Qué especialidades presentan mayores índices de inasistencia?
- ¿Qué características tienen los pacientes que cancelan o no asisten a sus citas?
- ¿Qué días y horarios presentan mayor probabilidad de ausentismo?
- ¿Qué sedes presentan menor utilización de consultorios?
- ¿Qué acciones podrían implementarse para reducir las inasistencias y optimizar la agenda médica?

El equipo deberá diseñar una arquitectura ELT adecuada para integrar la información de las distintas fuentes, seleccionar las herramientas tecnológicas más apropiadas y justificar cómo cada componente contribuye a mejorar el proceso analítico.

Fuentes de datos

La organización dispone de información proveniente de:

- **OpenEMR** (historias clínicas y consultas)
- **Microsoft SQL Server** (agenda de citas)
- **Microsoft Dynamics 365 Business Central** (facturación y servicios)
- Archivos de Microsoft Excel utilizados por las áreas administrativas
- Registros de confirmación de citas enviados por correo electrónico y SMS

Dataset de referencia (mockup): Healthcare No Show Appointment Data

<https://www.kaggle.com/datasets/samuelotiattakorah/healthcare-no-show-appointment-data/versions/1>